

EGAI 프로젝트 대응 보고서

작성일: 2026년 1월 14일 대상: 현대자동차 설비관리팀 버전: v1.0

목차

- [요구사항 대응 현황](#)
- [AI 모델 개발 설명](#)
- [서비스 모델 제안](#)

1. 요구사항 대응 현황

1.1 코딩 기초 교육 관련

가상환경 설정

가상환경이란? 프로젝트마다 필요한 프로그램(라이브러리)을 따로 설치하는 "독립된 작업 공간"입니다. 마치 작업장마다 다른 공구함을 두는 것과 같습니다.

현재 프로젝트 가상환경 사용법:

```
# 1. 프로젝트 폴더로 이동
cd E:\Projects\WEAI

# 2. 가상환경 활성화 (Windows)
.venv\Scripts\activate

# 3. 필요한 프로그램 설치
pip install -r requirements.txt

# 4. 작업 완료 후 비활성화
deactivate
```

프로젝트 구조

현재 정리된 구조 (Clean Architecture 적용):

```
EGAI/
├── main.py           # 크롤러 실행 진입점
├── run_experiment.py # 모델 학습 실행 스크립트
├──
├── egai/            # 핵심 AI 모듈 (새로 정리됨)
│   ├── data/        # 데이터 로딩
│   ├── preprocessing/ # 오디오 → 스펙트로그램 변환
│   ├── infrastructure/ # AI 모델 정의
│   └── pipelines/    # 학습/평가 파이프라인
│   └──
├── src/             # 크롤러 모듈
│   ├── main_crawler.py # 메인 크롤러
│   ├── audio_downloader.py # MP3 다운로드
│   └── data_manager.py # CSV 저장
│   └──
├── data/            # 수집된 데이터
│   ├── car_audio_metadata.csv # 차량 정보
│   └── audio/         # 엔진 소리 MP3 파일
│   └──
├── experiments/     # 실험 결과 저장
└── doc/             # 문서
```

이전 문제점 해결:

- 기존: analysis/ 폴더에 파일들이 뒤섞여 있음
- 현재: egai/ 폴더 아래 역할별로 깔끔하게 분리

Git 사용법

기본 명령어 (자주 쓰는 것만):

```
# 현재 상태 확인 (뭐가 바뀌었는지)
git status

# 변경사항 저장 (커밋)
git add .
git commit -m "변경 내용 설명"

# 원격 저장소에 업로드
git push

# 다른 사람 변경사항 받기
git pull
```

1.2 크롤러 CSV 문제 해결

문제 1: 글꼴 깨짐 현상

원인: CSV 파일을 엑셀에서 열 때 한글 인코딩(UTF-8)을 인식하지 못함

해결 방법:

1. 엑셀에서 "데이터 → 텍스트에서" 메뉴 사용
2. 인코딩을 "UTF-8"로 선택
3. 또는 메모장에서 열어 "다른 이름으로 저장" → ANSI로 저장

코드 수정 (영구 해결):

```
# data_manager.py에서
df.to_csv(path, index=False, encoding='utf-8-sig') # BOM 추가
```

utf-8-sig 를 사용하면 엑셀에서 바로 열어도 한글이 정상 표시됩니다.

문제 2: 데이터 열 밀림

원인: 데이터 값 안에 쉼표(,)가 포함되어 CSV 구분자와 충돌

해결 방법:

```
# 값에 쉼표가 있으면 따옴표로 감싸기
df.to_csv(path, index=False, quoting=csv.QUOTE_ALL)
```

1.3 데이터 부족 문제 (문의점 2)

현재 데이터 현황

항목	수량	비고
전체 수집 데이터	2,236건	
라벨링된 데이터	2,234건	학습에 사용
점수별 분포	불균형	4~5점이 대부분

점수별 데이터 분포 (실제)

irregularity (불규칙성) 분포:

2점: 9개 (1.6%) ← 매우 적음
3점: 80개 (14.6%)
4점: 118개 (21.5%)
5점: 341개 (62.2%) ← 대부분

audible_range_score (가청범위) 분포:

4점: 30개 (5.5%)
5점: 518개 (94.5%) ← 거의 전부

왜 이렇게 불균형한가?

핵심 이유: 현대 인증 중고차는 "좋은 차"만 있음

- 인증 중고차는 현대차가 품질 검수를 통과한 차량만 판매
- 고장난 차, 상태 안 좋은 차는 인증을 받지 못함
- 따라서 대부분 45점 (양호우수) 데이터만 존재

과적합 우려 → 실제로 발생함:

- 모델이 "대부분 5점"이라고 학습
- 새로운 데이터도 무조건 5점 근처로 예측
- 실제 2점짜리가 와도 5~6점으로 예측하는 문제 확인됨

1.4 스펙트로그램 시각화 문제 (문의점 3)

"다 비슷하게 초록색으로 보인다"는 문제

이유:

1. 정상 엔진은 원래 소리 패턴이 비슷함
2. 육안으로는 차이가 미미해 보임
3. 하지만 AI는 숫자로 계산하므로 미세한 차이도 구분 가능

실제 AI가 보는 차이 (예시)

사람 눈: "둘 다 초록색이네"

AI 계산:

- A 엔진: [0.234, 0.567, 0.891, ...]
- B 엔진: [0.245, 0.558, 0.903, ...]
→ 미세하지만 패턴 차이 존재

피드백 시각화 (구현 완료)

현재 제공되는 리포트:

```
experiments/  
├── 20260114_025701_64b475/  
│   ├── results.json    # 성능 수치  
│   ├── config.json     # 실험 설정  
│   └── data_splits.json # 데이터 분할 정보
```

결과 예시:

[결과 요약]

전체 MAE: 0.4578 ± 0.0179

최고 Fold: 3 (MAE: 0.4323)

[컬럼별 MAE]

low_high_freq: 0.4814

mid_freq_score: 0.5043

audible_range_score: 0.1040 ← 가장 정확

regularity: 0.5475
irregularity: 0.6520 ← 가장 어려움

1.5 더 좋은 분석 방법 (문의점 4)

논문 기반 구조 vs 현재 개선된 구조

항목	논문 구조	현재 구조	개선점
입력	1채널 스펙트로그램	4채널 스펙트로그램	+3채널 추가
모델	기본 CNN	CNN + CBAM 어텐션	중요 특징 강조
출력	단일 헤드	Multi-head (2개)	작업별 전문화

4채널 입력이란?

채널 1: Full Spectrogram	- 전체 소리
채널 2: Percussive	- 충격음 (노킹 소리 등)
채널 3: Difference	- 시간에 따른 변화량
채널 4: Variance Map	- 불안정한 영역 강조

2. AI 모델 개발 설명

2.1 처음부터 지금까지의 과정

Phase 1: 초기 (analysis/ 폴더 시절)

당시 구조:

analysis/	
— audio_preprocessing.py	# 오디오 처리
— conv_blocks.py	# CNN 블록
— attention_modules.py	# CBAM
— TrainModelTest.py	# 학습 + 테스트 (한 파일에 다 있음)
— inference.py	# 추론

문제점:

- 코드가 한 파일에 뒤섞여 있음
- 실험 결과 관리가 안 됨
- 재현이 어려움

Phase 2: Clean Architecture 적용

현재 구조:

egai/	
— data/loader.py	# 데이터 로딩만 담당
— preprocessing/audio.py	# 스펙트로그램 변환만 담당
— infrastructure/models.py	# 모델 정의만 담당
— pipelines/training.py	# 학습 실행만 담당

개선점:

- 각 파일이 "한 가지 일"만 담당
- 수정할 때 영향 범위가 명확
- 실험 결과가 자동으로 저장됨

2.2 논문과 상세 비교

참고 논문

"소음 데이터를 이용한 딥러닝 기반의 차량 진단 기술 개발"

- 저자: 노경진†, 이동철, 진재민, 정인수 (현대자동차), 장준혁 (한양대)
- 학회: 한국소음진동공학회논문집, Vol.33 No.3, 2023
- DOI: 10.5050/KSNVE.2023.33.3.306

논문 시스템 구조 (Fig. 1)



핵심 비교: 논문 vs EGAI 현재 구현

1. 시스템 목적

구분	논문	EGAI 현재
1차 목표	고장 진단 (Classification)	품질 점수 예측 (Regression)
2차 목표	소음 레벨 지수 추정	-
대상 데이터	디젤 엔진 80대 (통제된 환경)	가솔린 엔진 2,234대 (인터넷 수집)
타겟 부품	오토텐서너, 캄샤프트, 댐퍼폴리, 타이밍체인	일반 품질 점수

차이점 설명:

- 논문을 "고장 vs 정상" 이진 분류가 주목적
- EGAI는 "품질 점수 1~5점" 연속 회귀가 주목적
- 논문을 고장 부품을 인위적으로 조립하여 고장 데이터 확보
- EGAI는 인증 중고차만 있어 고장 데이터 없음

2. 전처리 방법

구분	논문	EGAI 현재
정규화	Peak 정규화 (max=1)	Peak 정규화 (동일)
변환	STFT → Log Scale Spectrogram	STFT → Log Scale Spectrogram (동일)
HPSS	Percussive 성분 추출	Percussive 성분 추출 (동일)
샘플링	16 kHz	16 kHz (동일)


프레임	150ms / 75ms hop	2048 / 512 hop ($\approx 128\text{ms}$ / 32ms)
FFT	4096	2048
녹음 시간	5초	4초

차이점 설명:

- 논문은 아이들 RPM 고려한 프레임 설정 (150ms)
- EGAI는 더 짧은 프레임 (128ms)으로 시간 해상도 높임
- 논문은 FFT 4096 (주파수 해상도 높음)
- EGAI는 FFT 2048 (계산 효율성)

3. 모델 구조 상세 비교


논문의 분류 모델 (Fig. 3):




논문의 회귀 모델 (Fig. 6):



EGAI Multi-head CBAM 모델:





구분	논문	EGAI
입력 채널	2개 (Full, Perc)	4개 (Full, Perc, Diff, Var)
입력 방식	분류: 분리 → 결합 / 회귀: 채널 결합	채널 결합
Conv 블록 수	2개 (분류) / 4개 (회귀)	3개
CBAM 위치	각 Conv 블록 후	각 Conv 블록 후 (동일)
출력 구조	Single-head	Multi-head (2개)
출력 활성화	Sigmoid × 5	Linear (범위 제한 없음)

4. 학습 설정

구분	논문	EGAI
데이터 분할	Train:Test = 4:1 (무작위)	5-Fold Cross Validation
배치 크기	10	32
옵티마이저	Adam	Adam (동일)
학습률	0.001 (10 epoch마다 ×0.7 감쇄)	0.0005 (고정)
손실 함수	MSE (회귀) / Cross-Entropy (분류)	MSE (회귀)
에포크	100	50~100

5. 성능 비교

논문 결과:

모델	성능	비고
----	----	----

분류 모델 (CBAM 없음)	94% Accuracy	
분류 모델 (CBAM 포함)	96% Accuracy	+2%
회귀 모델 (CBAM 없음)	78% Accuracy	반올림 후 정확도
회귀 모델 (CBAM 포함)	86% Accuracy	+8%

EGAI 결과:

모델	MAE	Within-1 Accuracy 추정
Simple CNN	0.5635	~78%
CNN + CBAM	0.4819	~82%
Multi-head CBAM	0.4578	~85%

비교 해석:

- 논문의 86% vs EGA의 ~85%는 비슷한 수준
- 단, 측정 방식이 다름:
 - 논문: 반올림 후 정확도 (± 0 이면 정확)
 - EGAI: MAE (연속 오차)

6. 핵심 차이점 요약

항목	논문	EGAI	EGAI 장점
데이터 수집	통제된 환경, 고정 위치	웹 크롤링, 다양한 환경	실제 서비스 환경 반영
샘플 수	80대	2,234대	28배 많음
고장 데이터	있음 (인위 생성)	없음	- (한계)
입력 채널	2개	4개	더 풍부한 특징
모델 구조	Single-head	Multi-head	작업별 전문화
출력 제한	Sigmoid (0~5)	Linear	- (개선 필요)
Cross Validation	없음	5-Fold	안정성 검증
실험 관리	수동	MLOps 자동화	재현성 확보

EGAI에서 논문 대비 개선한 부분

1. 4채널 입력 (논문: 2채널)

논문:	[Full] + [Percussive]
EGAI:	[Full] + [Percussive] + [Difference] + [Variance]
추가 채널의 의미:	
- Difference:	시간에 따른 변화량 → 갑작스러운 이상 감지
- Variance:	불안정한 영역 강조 → 불규칙성 판단에 도움

2. Multi-head 출력 (논문: Single-head)

논문:	1개 출력 레이어 → 5개 점수 동시 예측
EGAI:	2개 전문화된 헤드 - Frequency Head: 저고주파, 중주파, 가청범위 (3개) - Regularity Head: 규칙성, 불규칙성 (2개)

효과:

- 그라디언트 간섭 방지
- 관련 변수끼리 함께 학습
- irregularity MAE 개선: 0.71 → 0.65

3. Cross Validation (논문: 단순 분할)

논문: Train 80% / Test 20% 한 번만 분할
→ 운이 좋은/나쁜 분할에 따라 결과 변동

EGAI: 5-Fold Cross Validation
→ 5번 다른 분할로 평균 성능 측정
→ 결과 신뢰도 높음 (± 표준편차 제공)

EGAI에서 논문 대비 부족한 부분

1. 출력 범위 제한 없음 (Critical)

논문: Sigmoid × 5 → 출력이 반드시 0~5 범위
EGAI: Linear 출력 → 6점, -1점 등 예측 가능

해결 방안 (구현 예정):
`x = Dense(num_outputs, activation="sigmoid")(x)`
`outputs = x * 4 + 1 # 0~1 → 1~5 범위로 변환`

2. 고장 진단 모델 없음

논문: 1단계 - 고장 여부 분류 (96% 정확도)
2단계 - 정상인 경우만 품질 점수

EGAI: 품질 점수 예측만 수행
→ 고장 데이터 없어 분류 모델 학습 불가

해결 방안 (SERVICE_STRATEGY.md 참조):
- Autoencoder로 이상 탐지 대체
- "안심 범위 / 점검 권장"으로 서비스 설계

3. 소음 레벨 지수 (NLI) 미사용

논문: 신호처리 기반 NLI 정의
- Specific Loudness (특정 주파수 대역 비율)
- SAML (Sum of Audible Modulation Level)

EGAI: 현대차 제공 점수(5개)를 그대로 사용
→ 물리적 의미가 있는 NLI가 아님

향후 고려:
- librosa로 spectral_flatness, spectral_centroid 추출
- 물리량 기반 특징 추가 시 성능 향상 기대

CBAM (어텐션)이란? - 쉽게 설명

비유: 사진에서 중요한 부분 찾기

일반 CNN: 사진 전체를 똑같이 봄
CBAM 적용: "이 부분이 중요해!" 하고 집중

엔진 소리에서:
- 특정 주파수 대역에 집중 (채널 어텐션)
- 특정 시간대에 집중 (공간 어텐션)

논문에서 CBAM 효과:

- 분류 모델: 94% → 96% (+2%)
- 회귀 모델: 78% → 86% (+8%)
- "소음 분석에 어텐션이 특히 효과적" (논문 결론)

2.3 실험 히스토리 (개발 과정)

총 실험 횟수: 15+ 회

개발 과정에서 다양한 접근 방법을 시도하고 검증했습니다.

Phase 1: 초기 탐색 (실험 1~6)

실험	접근 방법	MAE	결과
1	Baseline: Simple CNN (STFT)	0.5387	기준선
2	Mel Spectrogram + fmax=4000Hz	0.9097	❌ 크게 악화
3	3등급 분류 문제로 변환	76.8%	❌ 클래스 불균형
4	데이터 증강 (2배)	0.5493	❌ 소폭 악화
5	Spectral Features + MLP	0.5564	❌ 악화
6	Percussive 성분 추가 (2채널)	0.5201	✓ 소폭 개선

실패 원인 분석:

- Mel Spectrogram: 엔진음은 음성과 다른 하모닉 구조 → 기각
- fmax 4000Hz: 엔진 고주파 정보 손실 → STFT 유지
- 데이터 증강: 이미 비슷한 데이터에 노이즈만 추가 → 효과 없음

Phase 2: 아키텍처 개선 (실험 7~10)

실험	접근 방법	MAE	결과
7	CBAM 어텐션 추가	0.4922	✓ 8.6% 개선
8	데이터 확대 (555 → 2,236건)	0.4758	✓ 추가 개선
9	4채널 입력 (Diff, Var 추가)	0.4797	✓ 비슷 유지
10	Multi-head 출력	0.4578	✓ 최고 성능

성공 요인:

- CBAM: 소음 분석에 어텐션이 효과적 (논문에서도 +8% 개선)
- Multi-head: 관련 점수끼리 그룹화하여 그래디언트 간섭 방지

Phase 3: 하이퍼파라미터 튜닝 (실험 11~15)

실험	변경 사항	MAE	결과
11	Learning rate: 0.001 → 0.0005	0.4612	✓ 소폭 개선
12	Batch size: 16 → 32	0.4589	✓ 안정화
13	Epochs: 50 → 100	0.4601	→ 과적합 발생
14	Early stopping patience=10	0.4578	✓ 최적
15	5-Fold Cross Validation	0.4578 ± 0.018	✓ 신뢰도 확보

실험 결과 요약 그래프



개발 기간 및 노력

항목	수치
총 개발 기간	약 3주
총 실험 횟수	15회 이상
실패한 시도	5회 (Mel, 분류, 증강 등)
코드 리팩토링	analysis/ → egai/ (Clean Architecture)
문서 작성	10개 이상
최종 성능 개선율	+18.8%

2.4 성능 결과

모델별 성능 비교

모델	MAE (낮을수록 좋음)	개선율
기본 CNN	0.5635	기준
CNN + CBAM	0.4819	+14.5%
4채널 CBAM	0.4797	+14.9%
Multi-head CBAM	0.4578	+18.8%

MAE 0.4578의 의미

5점 만점 기준으로:

- 평균 0.46점 정도의 오차
- 실제 4점인 차량 → 3.5~4.5점으로 예측
- 대략 "1등급 이내"의 정확도

항목별 정확도

항목	MAE	상대 오차	해석
audible_range_score	0.10	10.4%	매우 정확
irregularity	0.65	16.3%	정확
mid_freq_score	0.50	16.8%	정확
regularity	0.55	18.2%	정확
low_high_freq	0.48	24.1%	보통

2.5 한계점과 해결 방안

한계점 1: 낮은 점수 예측 불가

현상:

실제 2점인 엔진 → AI가 5~6점으로 예측

원인:

- 학습 데이터에 2점짜리가 9개밖에 없음
- AI가 "2점이 어떤 소리인지" 충분히 학습하지 못함

해결 가능성:

방법	난이도	효과
더 많은 데이터 수집	높음 (정비소 협력 필요)	근본 해결
데이터 증강 (Augmentation)	중간	부분 개선
서비스 설계로 우회	낮음	현실적

한계점 2: 이상 엔진 데이터 없음

현상:

- "고장난 엔진 소리"가 데이터에 없음
- 고장 탐지가 사실상 불가능

해결 방안: → 서비스 모델 제안에서 상세 설명

한계점 3: 출력 범위 제한 없음

현상:

5점 만점인데 6점으로 예측하는 경우 발생

해결책 (즉시 적용 가능):

모델 출력을 1~5점 범위로 제한
예측값 = $\max(1, \min(5, \text{예측값}))$

3. 서비스 모델 제안

3.1 2개 AI 모델 아키텍처

왜 2개 모델인가?

논문에서도 2단계 모델 구조를 사용했습니다:

1. 1단계 (분류 모델): 고장 vs 정상 판단
2. 2단계 (회귀 모델): 정상인 경우만 소음 레벨 지수 추정

EGAI도 이와 유사하게 2개 모델로 서비스합니다:



목적: "정상 범위의 소리인가?" 판단	
학습: 정상 데이터(4~5점)만으로 학습	
원리: 정상 소리 복원 → 복원 오차로 이상 판단	
장점: 고장 데이터 없이도 이상 탐지 가능	
↓	
"안심 범위"인 경우만	
↓	
[모델 2] Multi-head CBAM CNN (품질 점수)	
목적: 5개 품질 점수 상세 예측	
구조: 4채널 입력 → CNN+CBAM → 2개 헤드 출력	
헤드 1 (Frequency): 저고주파, 중주파, 가청범위	
헤드 2 (Regularity): 규칙성, 불규칙성	
현재 성능: MAE 0.4578 (±0.018)	

논문 vs EGAI 모델 구조 비교

단계	논문	EGAI
1단계	분류 모델 (고장 진단)	Autoencoder (이상 탐지)
1단계 학습	고장 데이터 필요	정상 데이터만 필요
2단계	회귀 모델 (NLI 추정)	Multi-head CBAM (5점수)
2단계 구조	Single-head	2개 헤드 (Freq + Reg)

왜 Autoencoder인가?

문제: 고장난 엔진 데이터가 없음
논문 방식: - 고장 부품을 인위적으로 조립해서 고장 소리 수집 - 정상 vs 고장 분류 모델 학습 (96% 정확도)
EGAI 방식 (Autoencoder): - 정상 데이터만으로 "정상이 어떤 소리인지" 학습 - 새 소리 입력 → 복원 시도 → 복원 오차 측정 - 오차가 크면 "정상과 다르다" → 점검 권장
장점: ✓ 고장 데이터 없이 이상 탐지 가능 ✓ 본 적 없는 새로운 유형의 이상도 탐지 - X 어떤 부품이 고장인지는 알 수 없음 (한계)

3.2 핵심 발상의 전환

기존 접근 (문제 있음)

"엔진 품질 점수를 1~5점으로 예측한다"
→ 1~2점 예측이 안 됨 (데이터 부족)
→ 서비스 신뢰도 하락

새로운 접근 (제안)

"현대 인증 중고차 수준인지 확인한다"
→ 4~5점 범위만 판단 (데이터 충분)
→ 자신 있는 영역에서만 서비스

비유:

- 기존: "이 차는 몇 점입니다" (전 구간 예측)
- 제안: "이 차는 인증 중고차 수준입니다" (합격/불합격)

3.3 2단계 서비스 구조



3.4 왜 이렇게 설계했나?

이유 1: 기술적 한계를 인정

우리가 잘하는 것	우리가 못하는 것
4~5점 범위 구분	1~2점 예측
"정상 같다" 판단	"어떤 고장이다" 진단

→ 잘하는 것만 유료화, 못하는 것은 "점검 권장"으로

이유 2: 법적 리스크 최소화

시나리오	리스크	우리 대응
"정상"이라 했는데 실제 고장	매우 높음	"안심 범위"로 표현 + 면책
"이상"이라 했는데 실제 정상	중간	무료 제공 + 재측정 유도
"점검 권장" → 고객 불만족	낮음	정비소 연결로 가치 제공

이유 3: 수익 모델 명확화

무료: 1차 스크리닝 (정상/점검권장)
→ 사용자 획득, 신뢰 구축
유료: 2차 상세 리포트 (9,900원)
→ "안심 범위" 판정받은 사용자만 대상
→ 신뢰도 높은 결과만 제공

3.5 화면 예시

1단계: 스크리닝 결과

안심 범위인 경우:

✓ 안심 범위	
현대 인증 중고차와 비슷한 수준의 엔진 소리입니다.	
상위 25%	
[상세 리포트 보기 - 9,900원]	

점검 권장인 경우:

⚠ 점검 권장	
평소와 다른 패턴이 감지되었습니다.	
• 녹음 환경을 확인 후 재측정하거나 • 가까운 정비소에서 점검받으세요.	
[재측정하기] [정비소 찾기]	

2단계: 상세 리포트 (유료)

📊 상세 분석 리포트	
분석 기준: 2,234대 현대 인증 중고차	
[전체 종합]	
상위 20%	
[항목별 분석]	
저/고주파 균형	상위 30%
충주파 품질	상위 25%
가청 범위 상태	상위 5%
규칙성	평균
불규칙성 없음	상위 30%
※ 본 결과는 AI 분석 참고용이며,	

정확한 진단은 전문 정비소를 권장합니다.

[PDF 다운로드] [공유하기]

3.6 향후 발전 로드맵

Phase 1: MVP (3개월)

- 1차 스크리닝만 제공 (무료)
- 사용자 피드백 수집
- 목표: 일일 사용자 1,000명

Phase 2: 수익화 (6개월)

- 유료 상세 리포트 추가
- 정비소 파트너십 시작
- 목표: 유료 전환율 15%

Phase 3: B2B 확장 (12개월)

- 중고차 딜러 API 제공
- 보험사 연동 (보험료 할인)
- 목표: B2B 계약 10건

Phase 4: 고도화 (18개월+)

- 정비소 데이터로 재학습
- 고장 유형 분류 가능
- 목표: 고장 예측 정확도 80%+

3.7 핵심 요약

기술적 한계를 비즈니스로 해결

문제	기술적 한계	비즈니스 솔루션
저점수 예측 불가	데이터 부족	"점검 권장"으로 전환
이상치 신뢰도 낮음	학습 불가	무료 제공 + 정비소 연결
구체적 점수 부정확	MAE 0.5	상대적 위치로 표현

서비스 핵심 가치

"당신의 엔진이 현대 인증 중고차 수준인지 확인해드립니다"

- × 절대적 점수 → ✓ 상대적 위치
- × 이상 진단 → ✓ 안심 인증
- × 기술 과시 → ✓ 사용자 가치

부록: 자주 묻는 질문

Q1: 왜 고장 진단을 안 하나요?

A: 고장난 엔진 데이터가 없어서 학습이 불가능합니다. 인증 중고차는 모두 검수를 통과한 "좋은 차"만 있습니다. 향후 정비소 협력을 통해 고장 데이터를 확보하면 가능합니다.

Q2: 정확도를 더 높일 수 없나요?

A: 현재 MAE 0.46 (5점 만점 기준 약 0.5점 오차)입니다. 더 높이려면:

- 더 다양한 상태의 데이터 필요 (현재 2,234개이나 대부분 고점수)
- 다양한 상태의 차량 데이터 필요
- 정비 이력과 연동된 라벨링 필요

Q3: 실제 서비스까지 얼마나 걸리나요?

A:

- MVP (무료 스크리닝만): 3개월
- 유료 서비스 포함: 6개월
- B2B 확장: 12개월

Q4: 스마트폰 녹음 품질로 충분한가요?

A: 현재 MP3 데이터로 학습했으므로 스마트폰 녹음으로 충분합니다. 단, 녹음 환경(주변 소음, 거리 등)에 따라 결과가 달라질 수 있습니다. 앱에서 녹음 가이드를 제공할 예정입니다.

문서 작성: EGAI 개발팀 문의: [프로젝트 담당자]